

SCALAB

Universidad Carlos III de Madrid

Incertidumbre

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

Introducción

Modelos de Markov

Modelos de Markov Ocultos (HMMs)

Procesos de Decisión de Markov (MDPs)

Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

Introducción

Modelos de Markov

Modelos de Markov Ocultos (HMMs)

Procesos de Decisión de Markov (MDPs)

Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

- Introducción

- Modelos de Markov

- Modelos de Markov Ocultos (HMMs)

- Procesos de Decisión de Markov (MDPs)

- Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

Introducción

Modelos de Markov

Modelos de Markov Ocultos (HMMs)

Procesos de Decisión de Markov (MDPs)

Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa

Probabilidades, Tiempo, Acciones

► Razonamiento probabilístico en el tiempo

- Hasta ahora: razonamiento probabilístico en mundos estáticos
- El mundo es dinámico ¿Cómo podemos considerar el **paso del tiempo**?
- **Por ejemplo, cómo afecta el hecho de que lloviera ayer (L_{lueve_t}) al hecho de que llueva hoy ($L_{\text{lueve}_{t+1}}$)**
- Modelos de Markov (MM) (también denominados Procesos de Markov o cadenas de Markov) y **Modelos de Markov ocultos (HMM)**

Probabilidades, Tiempo, Acciones

► Razonamiento probabilístico en mundos no deterministas

- Los algoritmos de búsqueda proporcionan una secuencia de acciones para resolver el problema, pero
- ¿Qué pasa si las **acciones no son deterministas**?
- ¿Cómo podemos elegir las acciones que tienen más probabilidad de llevarnos al estado meta?
- Procesos de Decisión de Markov (MDPs) y Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

Introducción

Modelos de Markov


Modelos de Markov Ocultos (HMMs)

Procesos de Decisión de Markov (MDPs)

Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa

Modelos de Markov




- ▶ N estados: s_1, s_2, \dots, s_N
- ▶ Instantes de tiempo discretos:
 $t = 0, t = 1, \dots$
- ▶ En un instante t el sistema está en un estado E_t

$$E_t \in \{s_1, s_2, \dots, s_N\}$$

- ▶ El estado actual determina la distribución de probabilidad del estado siguiente

Modelos de Markov




- N estados: s_1, s_2, \dots, s_N
- Instantes de tiempo discretos:
 $t = 0, t = 1, \dots$
- En un instante t el sistema está en un estado E_t

$$E_t \in \{s_1, s_2, \dots, s_N\}$$

- El estado actual determina la distribución de probabilidad del estado siguiente

Modelos de Markov

$$P(E_{t+1}=s1/E_t=s2)$$




- N estados: s_1, s_2, \dots, s_N
- Instantes de tiempo discretos:
 $t = 0, t = 1, \dots$
- En un instante t el sistema está en un estado E_t

$$E_t \in \{s1, s2, \dots, s_N\}$$

- El estado actual determina la distribución de probabilidad del estado siguiente

Modelos de Markov

$$P(E_{t+1}=s1/E_t=s2)$$




► Hipótesis de Markov

- E_{t+1} es condicionalmente independiente de E_{t-1}, \dots, E_0 dado E_t
- Es decir, el **estado actual solo depende del anterior**

Modelos de Markov

$$P(E_{t+1}=s1/E_t=s2)$$




► Hipótesis de Markov

- E_{t+1} es condicionalmente independiente de E_{t-1}, \dots, E_0 dado E_t
- Es decir, el **estado actual solo depende del anterior**

$$P(E_{t+1}/E_t, E_{t-1}, \dots) = P(E_{t+1}/E_t)$$

Modelos de Markov



► Hipótesis de Markov

- E_{t+1} es condicionalmente independiente de E_{t-1}, \dots, E_0 dado E_t
- Es decir, el **estado actual solo depende del anterior**

$$P(E_{t+1}/E_t, E_{t-1}, \dots) = P(E_{t+1}/E_t)$$

- La distribución conjunta $P(E_0, E_1, E_2, \dots)$ se puede representar con una red bayesiana

Modelos de Markov


► Hipótesis de Markov

- E_{t+1} es condicionalmente independiente de E_{t-1}, \dots, E_0 dado E_t
- Es decir, el **estado actual solo depende del anterior**

$$P(E_{t+1}/E_t, E_{t-1}, \dots) = P(E_{t+1}/E_t)$$

- La distribución conjunta $P(E_0, E_1, E_2, \dots)$ se puede representar con una red bayesiana

$$P(E_{t+1}=s1/E_t=s2)$$



Modelos de Markov

► Hipótesis de Markov

- E_{t+1} es condicionalmente independiente de E_{t-1}, \dots, E_0 dado E_t
- Es decir, el **estado actual solo depende del anterior**


$$P(E_{t+1}/E_t, E_{t-1}, \dots) = P(E_{t+1}/E_t)$$

- La distribución conjunta $P(E_0, E_1, E_2, \dots)$ se puede representar con una red bayesiana

- Prob a priori: $P(E_0)$

- CPTs: $P(E_{t+1}/E_t)$

$$P(E_{t+1}=s1/E_t=s2)$$



Modelos de Markov

► Hipótesis de Markov

- E_{t+1} es condicionalmente independiente de E_{t-1}, \dots, E_0 dado E_t
- Es decir, el **estado actual solo depende del anterior**

$$P(E_{t+1}/E_t, E_{t-1}, \dots) = P(E_{t+1}/E_t)$$


- La distribución conjunta $P(E_0, E_1, E_2, \dots)$ se puede representar con una red bayesiana

- Prob a priori: $P(E_0)$

- CPTs: $P(E_{t+1}/E_t)$


- Proceso estacionario: las CPTs no cambian con el tiempo → ¡basta con definir una!

$$P(E_{t+1}=s1/E_t=s2)$$




Ejemplo

Un humano y un robot se mueven por un grid ...



Ejemplo

Un humano y un robot se mueven por un grid ...



Número de estados = $18 \times 18 = 324$

Ejemplo

- ▶ En cada instante de tiempo el robot se mueve a una celda adyacente y el humano se mueve también a una celda adyacente
- ▶ Estado inicial, E_0 :

					R
H					

Ejemplo

- ▶ En cada instante de tiempo el robot se mueve a una celda adyacente y el humano se mueve también a una celda adyacente
- ▶ Estado inicial, E_0 :

					R
H					

- ▶ Preguntas típicas
 - ▶ ¿Cuál es el tiempo esperado para que el robot alcance al humano?
 - ▶ ¿Cuál es la probabilidad de que el robot alcance al humano en el próximo instante?
 - ▶ ¿Cuál es la probabilidad de que el robot alcance al humano en N instantes?

Ejemplo de pregunta

Estamos en tiempo t y el humano no ha sido alcanzado. ¿Cuál es la probabilidad de que el alcance ocurra en $t+1$?

- Caso 1: Si el robot es ciego → Modelos de Markov (MM)

Ejemplo de pregunta

Estamos en tiempo t y el humano no ha sido alcanzado. ¿Cuál es la probabilidad de que el alcance ocurra en $t+1$?

- ▶ Caso 1: Si el robot es ciego → Modelos de Markov (MM)
- ▶ Caso 2: Si el robot tiene algunos sensores, pero la información sobre el estado es incompleta → Modelos de Markov Ocultos (HMM)

Ejemplo de pregunta

Estamos en tiempo t y el humano no ha sido alcanzado. ¿Cuál es la probabilidad de que el alcance ocurra en $t+1$?

- ▶ Caso 1: Si el robot es ciego → Modelos de Markov (MM) Veremos esto primero
- ▶ Caso 2: Si el robot tiene algunos sensores, pero la información sobre el estado es incompleta → Modelos de Markov Ocultos (HMM)

Modelos de Markov: ¿Cuál es la probabilidad $P(E_t = s_j)$?

- Paso 1: Calcular la probabilidad de todos los posibles caminos
 - Dado que conocemos $P(E_0 = s_i) = 1$

$$P(E_0, E_1, \dots, E_t) = P(E_1/E_0)P(E_2/E_1) \dots P(E_t/E_{t-1})$$

Modelos de Markov: ¿Cuál es la probabilidad $P(E_t = s_j)$?

- Paso 1: Calcular la probabilidad de todos los posibles caminos

- Dado que conocemos $P(E_0 = s_i) = 1$

$$P(E_0, E_1, \dots, E_t) = P(E_1/E_0)P(E_2/E_1) \dots P(E_t/E_{t-1})$$

- Paso 2: marginamos $P(E_t = s_j)$

$$P(E_t = s_j) = \sum_{\text{Todos los caminos que acaban en } s_j} P(E_0, E_1, \dots, E_t = s_j)$$

Modelos de Markov: ¿Cuál es la probabilidad $P(E_t = s_j)$?

- Paso 1: Calcular la probabilidad de todos los posibles caminos

- Dado que conocemos $P(E_0 = s_i) = 1$

$$P(E_0, E_1, \dots, E_t) = P(E_1/E_0)P(E_2/E_1) \dots P(E_t/E_{t-1})$$

- Paso 2: marginamos $P(E_t = s_j)$

$$P(E_t = s_j) = \sum_{\text{Todos los caminos que acaban en } s_j} P(E_0, E_1, \dots, E_t = s_j)$$

- ¡El cálculo es **exponencial en t!**

¿Cuál es la probabilidad $P(E_t = s_j)$? Método más inteligente: **Programación dinámica**

- Definir para cada estado s_i la probabilidad de estar en ese estado en el instante t

$$P(E_t = s_i)$$

¿Cuál es la probabilidad $P(E_t = s_j)$? Método más inteligente: Programación dinámica

- Definir para cada estado s_i la probabilidad de estar en ese estado en el instante t

$$P(E_t = s_i)$$

- Mediante una definición recursiva:

$$\forall i, P(E_0 = s_i) = \begin{cases} 1 & \text{Si } s_i \text{ es el estado inicial} \\ 0 & \text{En otro caso} \end{cases}$$

¿Cuál es la probabilidad $P(E_t = s_j)$? Método más inteligente: **Programación dinámica**

- Definir para cada estado s_i la probabilidad de estar en ese estado en el instante t

$$P(E_t = s_i)$$

- Mediante una definición **recursiva**:

$$\forall i, P(E_0 = s_i) = \begin{cases} 1 & \text{Si } s_i \text{ es el estado inicial} \\ 0 & \text{En otro caso} \end{cases}$$

$$\forall j, P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j, E_t = s_i) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

¿Cuál es la probabilidad $P(E_t = s_j)$? Método más inteligente: **Programación dinámica**

- Definir para cada estado s_i la probabilidad de estar en ese estado en el instante t

$$P(E_t = s_i)$$

- Mediante una definición **recursiva**:

$$\forall i, P(E_0 = s_i) = \begin{cases} 1 & \text{Si } s_i \text{ es el estado inicial} \\ 0 & \text{En otro caso} \end{cases}$$

$$\forall j, P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j, E_t = s_i) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

- El cálculo equivale a rellenar la siguiente tabla como muestran las flechas

t	$P(E_t = s_1)$	$P(E_t = s_2)$...	$P(E_t = s_N)$
1	0	1	0	0
2				
...				
t final				

¿Cuál es la probabilidad $P(E_t = s_j)$? Método más inteligente: **Programación dinámica**

- Definir para cada estado s_i la probabilidad de estar en ese estado en el instante t

$$P(E_t = s_i)$$

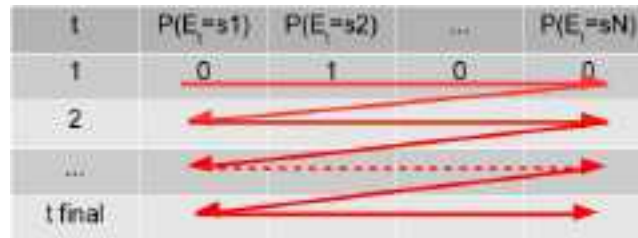
- Mediante una definición **recursiva**:

$$\forall i, P(E_0 = s_i) = \begin{cases} 1 & \text{Si } s_i \text{ es el estado inicial} \\ 0 & \text{En otro caso} \end{cases}$$

$$\forall j, P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j, E_t = s_i) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

- El cálculo equivale a rellenar la siguiente tabla como muestran las flechas

t	$P(E_t = s_1)$	$P(E_t = s_2)$...	$P(E_t = s_N)$
1	0	1	0	0
2				
...				
t final				



- Algoritmo de **Simulación hacia delante**: **complejidad lineal en t**

¿Cuál es la probabilidad $P(E_t = s_j)$? Método más inteligente: **Programación dinámica**

- Definir para cada estado s_i la probabilidad de estar en ese estado en el instante t

$$P(E_t = s_i)$$

- Mediante una definición **recursiva**:

$$\forall i, P(E_0 = s_i) = \begin{cases} 1 & \text{Si } s_i \text{ es el estado inicial} \\ 0 & \text{En otro caso} \end{cases}$$

$$\forall j, P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j, E_t = s_i) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$


- El cálculo equivale a rellenar la siguiente tabla como muestran las flechas

t	$P(E_t = s_1)$	$P(E_t = s_2)$...	$P(E_t = s_N)$
1	0	1	0	0
2				
...				
t final				

- Algoritmo de **Simulación hacia delante**: **complejidad lineal en t**


Ejemplo pequeño

- ▶ Estados: $E_t = \{Tiempo_t\}$
- ▶ Transiciones: $P(E_t/E_{t-1})$



Ejemplo pequeño


- ▶ Estados: $E_t = \{Tiempo_t\}$
- ▶ Transiciones: $P(E_t/E_{t-1})$



- ▶ Inicialmente, $P(E_0 = sol) = 1, P(E_0 = lluvia) = 0$

Ejemplo pequeño


- ▶ Estados: $E_t = \{Tiempo_t\}$
- ▶ Transiciones: $P(E_t/E_{t-1})$



- ▶ Inicialmente, $P(E_0 = sol) = 1$, $P(E_0 = lluvia) = 0$
- ▶ ¿Cuál es la probabilidad de sol al día siguiente, E_1 ?

Ejemplo pequeño

- ▶ Estados: $E_t = \{Tiempo_t\}$
- ▶ Transiciones: $P(E_t/E_{t-1})$



- ▶ Inicialmente, $P(E_0 = sol) = 1, P(E_0 = lluvia) = 0$
- ▶ ¿Cuál es la probabilidad de sol al día siguiente, E_1 ?

$$\begin{aligned} P(E_1 = sol) &= P(E_1 = sol/E_0 = sol)P(E_0 = sol) + P(E_1 = sol/E_0 = lluvia)P(E_0 = lluvia) \\ &= 0.9 \times 1.0 + 0.1 \times 0.0 = 0.9 \end{aligned}$$

Ejemplo pequeño: simulación hacia delante

- ▶ ¿Cuál es la distribución de probabilidad tras k pasos?
- ▶ Algoritmo de **simulación hacia delante**

Ejemplo pequeño: simulación hacia delante

- ▶ ¿Cuál es la distribución de probabilidad tras k pasos?
- ▶ Algoritmo de **simulación hacia delante**

$$P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$


- ▶ $P(E_0)$ conocido

Ejemplo pequeño: simulación hacia delante

- ¿Cuál es la distribución de probabilidad tras k pasos?
- Algoritmo de **simulación hacia delante**

$$P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

- $P(E_0)$ conocido




Ejemplo pequeño: simulación hacia delante

- ¿Cuál es la distribución de probabilidad tras k pasos?
- Algoritmo de **simulación hacia delante**

$$P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

- $P(E_0)$ conocido

$P(E_t = sol) :$



$P(E_t = lluvia) :$

Ejemplo pequeño: simulación hacia delante


- ¿Cuál es la distribución de probabilidad tras k pasos?
- Algoritmo de **simulación hacia delante**

$$P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

- $P(E_0)$ conocido E_0

$P(E_t = sol) :$

1.0



$P(E_t = lluvia) :$

0.0

Ejemplo pequeño: simulación hacia delante

- ¿Cuál es la distribución de probabilidad tras k pasos?
- Algoritmo de **simulación hacia delante**


$$P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

- $P(E_0)$ conocido

 E_0 E_1 $P(E_t = sol) :$

1.0

0.9

 $P(E_t = lluvia) :$

0.0

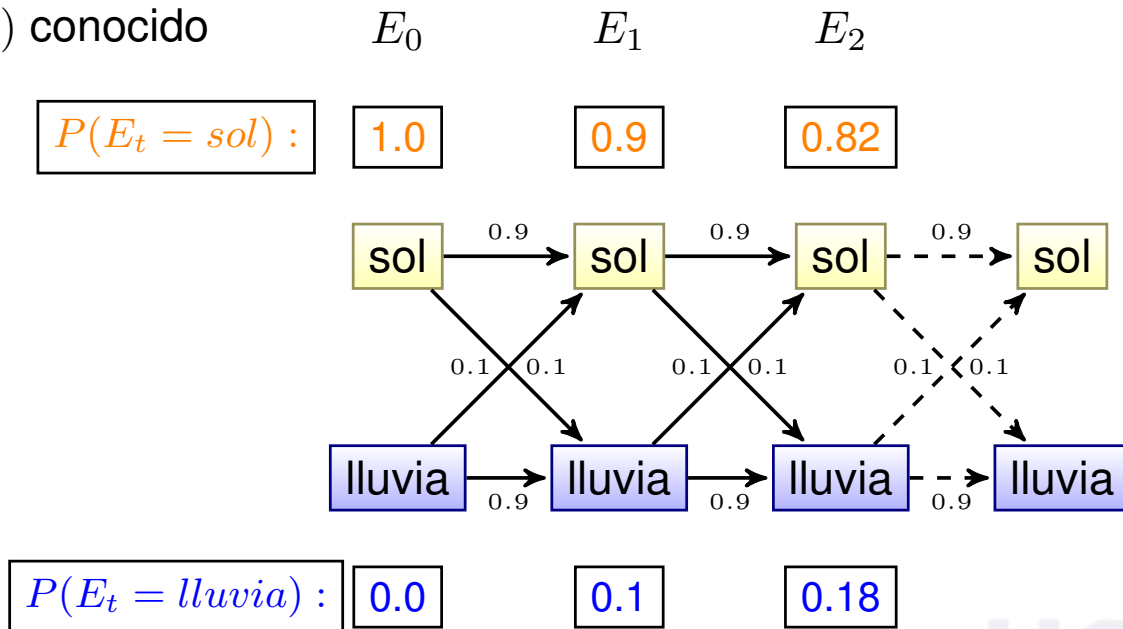
0.1

Ejemplo pequeño: simulación hacia delante

- ¿Cuál es la distribución de probabilidad tras k pasos?
- Algoritmo de **simulación hacia delante**

$$P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

- $P(E_0)$ conocido

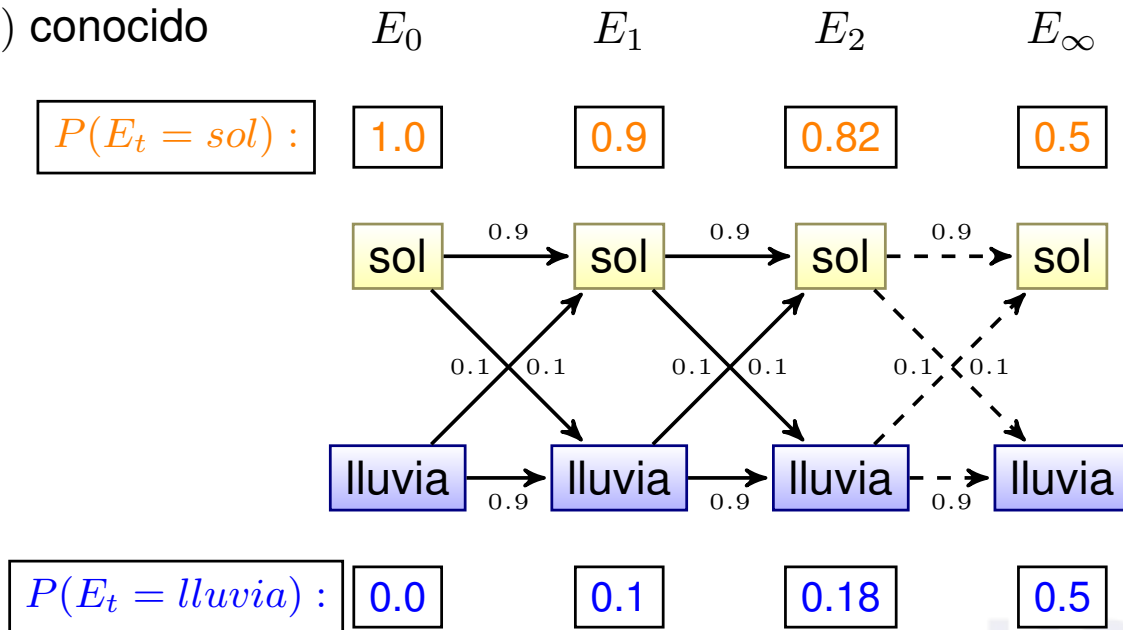


Ejemplo pequeño: simulación hacia delante

- ¿Cuál es la distribución de probabilidad tras k pasos?
- Algoritmo de **simulación hacia delante**

$$P(E_{t+1} = s_j) = \sum_{i=1}^N P(E_{t+1} = s_j / E_t = s_i) P(E_t = s_i)$$

- $P(E_0)$ conocido



Distribuciones estacionarias

- ▶ Si simulamos la cadena una cantidad suficiente de pasos
 - ▶ La incertidumbre se acumula
 - ▶ Eventualmente, ¿no sabremos cuál es el estado!
- ▶ Distribuciones estacionarias
 - ▶ Para la mayoría de las cadenas la distribución al final es independiente de la inicial
la distribución al final es igual si empezamos con $P(X_0 = lluvia) = 1$
 - ▶ **Normalmente sólo podemos predecir a corto plazo**

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

Introducción

Modelos de Markov

Modelos de Markov Ocultos (HMMs)

Procesos de Decisión de Markov (MDPs)

Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa

Volviendo al ejemplo del robot

Estamos en tiempo t y el humano no ha sido alcanzado. ¿Cuál es la probabilidad de que el alcance ocurra en $t+1$?

- Caso 1: Si el robot es ciego \rightarrow Modelos de Markov (MM) (Hemos visto esto)

Volviendo al ejemplo del robot

Estamos en tiempo t y el humano no ha sido alcanzado. ¿Cuál es la probabilidad de que el alcance ocurra en $t+1$?

- ▶ Caso 1: Si el robot es ciego \rightarrow Modelos de Markov (MM) (Hemos visto esto)
- ▶ Caso 2: Si el robot tiene algunos sensores, pero la información sobre el estado es incompleta \rightarrow Modelos de Markov Ocultos (HMM)


Volviendo al ejemplo del robot

Estamos en tiempo t y el humano no ha sido alcanzado. ¿Cuál es la probabilidad de que el alcance ocurra en $t+1$?


- ▶ Caso 1: Si el robot es ciego \rightarrow Modelos de Markov (MM) (Hemos visto esto)
- ▶ Caso 2: Si el robot tiene algunos sensores, pero la información sobre el estado es incompleta \rightarrow Modelos de Markov Ocultos (HMM) Ahora veremos esto

Modelos de Markov Ocultos (HMM)

- ▶ El **estado no es observable** (está oculto), pero...
- ▶ Hay **variables observables** (evidencia) que determinan el estado
- ▶ **Ejemplo robot: sensores de proximidad. El robot ve las 8 celdas adyacentes**
- ▶ **Los sensores son imperfectos**




Estado verdadero en t



observación correcta

W: Pared

Observación con ruido
(sensores imperfectos)

Modelos de Markov Ocultos (HMMs)

- ▶ Se asume
 - ▶ Que es un proceso estacionario
 - ▶ Que se cumple la hipótesis de Markov
 - ▶ Que las observaciones en t (O_t) sólo dependen del estado en t (E_t)


$$P(O_t/E_t, \text{historia anterior}) = P(O_t/E_t)$$

Modelos de Markov Ocultos (HMMs)

- ▶ Se asume
 - ▶ Que es un proceso estacionario
 - ▶ Que se cumple la hipótesis de Markov
 - ▶ Que las observaciones en t (O_t) sólo dependen del estado en t (E_t)

$$P(O_t/E_t, \text{historia anterior}) = P(O_t/E_t)$$

- ▶ La red bayesiana correspondiente es:



HMMs


- ▶ Un HMM se define por
 - ▶ Un conjunto de estados
 - ▶ Un conjunto de observaciones
 - ▶ La probabilidad a priori $P(E_0)$
 - ▶ El modelo de transiciones $P(E_{t+1}/E_t)$
 - ▶ El modelo de observaciones $P(O_t/E_t)$

Exemplo pequeño

- ▶ *Un estudiante estudia día tras día en su estudio sin ventanas, pero ve a una persona entrar de la calle cada día y puede ver si lleva o no paraguas*
- ▶ Estados: Lluvia (si, no)
- ▶ Observaciones: Paraguas (si, no)

Exemplo pequeño

- *Un estudiante estudia día tras día en su estudio sin ventanas, pero ve a una persona entrar de la calle cada día y puede ver si lleva o no paraguas*
- Estados: Lluvia (si, no)
- Observaciones: Paraguas (si, no)



Tareas Típicas de Inferencia

- Problema de **Evaluación** : calcular la probabilidad de una secuencia de observaciones

$$P(O_o, O_1, \dots, O_t)$$

¿Cuál es la probabilidad de llevar paraguas tres días seguidos?

Tareas Típicas de Inferencia

- Problema de **Decodificación**: dada una secuencia de observaciones O_o, O_1, \dots, O_t , determinar cuál es la secuencia de estados correspondiente que *explica mejor* esas observaciones.

$$\arg \max_{E_0, \dots, E_{n+1}} P(O_o, \dots, O_n, E_1, \dots, E_{n+1})$$

Dado que llevé paraguas tres días seguidos, ¿cuál es la probabilidad de que esos tres días haya llovido?

Tareas Típicas de Inferencia

- Problema de **Filtrado**. Distribución de probabilidad del estado actual dada cierta evidencia histórica

$$P(E_t/O_0, \dots, O_t)$$

Dado que la persona llevó paraguas tres días ¿cuál es la probabilidad de que esté lloviendo el día tres?

Tareas Típicas de Inferencia

- Problema de **Predicción**. Distribución de probabilidad de estados futuros dada evidencia

$$P(E_{t+k}/O_0, \dots, O_t)$$

Dado que la persona llevó paraguas tres días ¿cuál es la probabilidad de que llueva pasado mañana?

Inferencia en HMMs

- En los HMM la distribución conjunta factoriza como:

$$P(E_0, \dots, E_t, O_0, \dots, O_t) = P(O_0/E_0)P(E_0) \prod_{t=1}^T P(E_t/E_{t-1})P(O_t/E_t)$$


Inferencia en HMMs

- ▶ En los HMM la distribución conjunta factoriza como:

$$P(E_0, \dots, E_t, O_0, \dots, O_t) = P(O_0/E_0)P(E_0) \prod_{t=1}^T P(E_t/E_{t-1})P(O_t/E_t)$$

- ▶ Al igual que en MM es posible una **definición recursiva**
- ▶ Muchas de las tareas de inferencia en HMM se resuelven de forma eficiente con **programación dinámica** (aunque no veremos esto en este curso)
- ▶ Resolveremos HMM mediante inferencia exacta en redes bayesianas.

Ejemplo pequeño de filtrado



$$P(LLuvia_0): P(Lluvia_0 = si) = 0.5$$

$$P(Lluvia_{t+1}/Lluvia_t):$$

L_t	$P(L_{t+1} = si/L_t)$
si	0.7
no	0.3

$$P(Paraguas_t/Lluvia_t):$$

L_t	$P(P_t = si/L_t)$
si	0.9
no	0.2

Ejemplo pequeño de filtrado

- Probabilidad de que hoy esté lloviendo si ha traído paraguas dos días seguidos

$$P(L_1 = si / P_0 = si, P_1 = si)$$

Ejemplo pequeño de filtrado

- Probabilidad de que hoy esté lloviendo si ha traído paraguas dos días seguidos

$$P(L_1 = si / P_0 = si, P_1 = si)$$

$$\begin{aligned}
 P(L_1 = si / P_0 = si, P_1 = si) &= \\
 &= \alpha P(L_1 = si, P_0 = si, P_1 = si) \\
 &= \alpha \sum_{l_0} P(L_0 = l_0, L_1 = si, P_0 = si, P_1 = si) \\
 &= \alpha \sum_{l_0} P(L_1 = si / L_0 = l_0) P(L_0 = l_0) P(P_0 = si / L_0 = l_0) P(P_1 = si / L_1 = si) \\
 &= \alpha P(P_1 = si / L_1 = si) \sum_{l_0} P(L_1 = si / L_0 = l_0) P(L_0 = l_0) P(P_0 = si / L_0 = l_0) \\
 &= \alpha P(P_1 = si / L_1 = si) [P(L_1 = si / L_0 = si) P(L_0 = si) P(P_0 = si / L_0 = si) \\
 &\quad + P(L_1 = si / L_0 = no) P(L_0 = no) P(P_0 = si / L_0 = no)] \\
 &= \alpha \times 0.9 \times [0.7 \times 0.5 \times 0.9 + 0.3 \times 0.5 \times 0.2] \\
 &= \alpha \times 0.3105
 \end{aligned}$$

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

Introducción

Modelos de Markov

Modelos de Markov Ocultos (HMMs)


Procesos de Decisión de Markov (MDPs)

Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa

Proceso de decisión de Markov (MDP)

- ▶ Proceso de Markov en el que se toma una decisión (acción) en cada instante
- ▶ Caso general: acciones no deterministas



Proceso de decisión de Markov (MDP)

- Proceso de Markov en el que se toma una decisión (acción) en cada instante

Proceso de decisión de Markov (MDP)

- ▶ Proceso de Markov en el que se toma una decisión (acción) en cada instante
- ▶ Las probabilidades de transición dependen de las acciones

$$P(S_{t+1} = s' | S_t = s, A_t = a) = P(s' / s, a)$$

Proceso de decisión de Markov (MDP)

- ▶ Proceso de Markov en el que se toma una decisión (acción) en cada instante
- ▶ Las probabilidades de transición dependen de las acciones

$$P(S_{t+1} = s' | S_t = s, A_t = a) = P(s' / s, a)$$

- ▶ Hay un refuerzo o un coste por cada par estado-acción

$$R(S_t = s, A_t = a) = R(s, a)$$



- ▶ Algunas veces se utiliza $R(s)$ en lugar de $R(s, a)$

Proceso de decisión de Markov (MDP)

- ▶ Se definen como una tupla: $\langle S, A, P, R \rangle$
 - ▶ S : estados (incluyendo estado inicial y final)
 - ▶ A : acciones
 - ▶ P : tabla de transiciones $P(s'|s, a)$
 - ▶ R : refuerzo o coste $R(s, a)$
- ▶ Objetivo: determinar qué acción ejecutar en **cada** estado para maximizar el refuerzo o minimizar el coste a largo plazo

Ejemplo

- Acciones: norte, sur, este, oeste
- Incertidumbre sobre el resultado de la ejecución de acciones



Acción: NORTE
(si pared la probabilidad va al mismo estado)

Ejemplo: **Tupla MDP:** $\langle S, A, P, R \rangle$

- ▶ S : posición del robot
 - ▶ Estado inicial: $X_0 = c1$
 - ▶ Estado final: $X_n = a4$ ó $b4$

Ejemplo: **Tupla MDP:** $\langle S, A, P, R \rangle$

- ▶ S : posición del robot
 - ▶ Estado inicial: $X_0 = c1$
 - ▶ Estado final: $X_n = a4$ ó $b4$
- ▶ A : norte, sur, este, oeste

Ejemplo: **Tupla MDP:** $\langle S, A, P, R \rangle$

- ▶ S : posición del robot
 - ▶ Estado inicial: $X_0 = c1$
 - ▶ Estado final: $X_n = a4$ ó $b4$
- ▶ A : norte, sur, este, oeste
- ▶ P : Función de transición
 - ▶ $P(X_t = b1/X_{t-1} = c1, \text{norte}) = 0.8$
 - ▶ $P(X_t = c1/X_{t-1} = c1, \text{norte}) = 0.1$
 - ▶ $P(X_t = c2/X_{t-1} = c1, \text{norte}) = 0.1$
 - ▶ ...

Ejemplo: **Tupla MDP:** $\langle S, A, P, R \rangle$

- ▶ S : posición del robot
 - ▶ Estado inicial: $X_0 = c1$
 - ▶ Estado final: $X_n = a4$ ó $b4$
- ▶ A : norte, sur, este, oeste
- ▶ P : Función de transición
 - ▶ $P(X_t = b1 / X_{t-1} = c1, \text{norte}) = 0.8$
 - ▶ $P(X_t = c1 / X_{t-1} = c1, \text{norte}) = 0.1$
 - ▶ $P(X_t = c2 / X_{t-1} = c1, \text{norte}) = 0.1$
 - ▶ ...
- ▶ R : refuerzo
 - ▶ $R(X = a4) = 100, R(X = b4) = -100$
 - ▶ Para cualquier otra casilla x : $R(X = x) = 0$


Política

- ▶ Una **Política** es un mapeo completo de estados a acciones
- ▶ Una política es **parecido a un plan**, pero no es exactamente un plan
 - ▶ Se genera hacia delante en el tiempo, como un plan
- ▶ Pero, **no es una secuencia de acciones**
 - ▶ Con una política, si hay fallos en la ejecución el agente puede seguir ejecutando
 - ▶ Prescribe una acción para cada estado
- ▶ Maximiza el refuerzo esperado (o minimiza el coste esperado) en lugar de alcanzar un estado meta
- ▶ Para cada MDP **existe una política óptima**
 - ▶ Para cada estado posible, no hay mejor opción que seguir la política


Camino (plan) vs. política (acciones estocásticas)

- ▶ Acción estocástica: consigue el efecto deseado con probabilidad p
- ▶ Ejemplo: La acción *norte* mueve hacia el norte con probabilidad 0.8, hacia el oeste con 0.1 y hacia el este con 0.1
- ▶ No hay “camino óptimo”
- ▶ La política determina qué hacer independientemente del efecto de cualquier acción en cualquier instante de tiempo

Ejemplo: robot – política




Ejemplo: robot – política




¿Cuál es la política óptima?

Ejemplo: robot – política óptima



Ejemplo: robot – política óptima



- ▶ Ésta es la política óptima porque no hay coste asociado a los demás estados
- ▶ Lo único importante es llegar al estado con refuerzo 100 evitando al máximo no caer en el estado con refuerzo -100
- ▶ No se da importancia a realizar un recorrido más largo

Ejemplo: robot – con coste (o refuerzo negativo) asociado a los demás estados

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

MDP: propiedades

- Podemos razonar sobre
 - maximizar el refuerzo esperado:

$$\max E \left[\sum_{t=0}^{\infty} \gamma^t R(s_t) \right]$$

$\gamma \in [0, 1]$ es el factor de descuento

- minimizar el coste esperado:

$$\min E \left[\sum_{t=0}^H C(s_t) \right]$$

Para el caso de minimizar el coste

- Política óptima π^* : mínimo coste esperado

Para el caso de minimizar el coste

- ▶ Política óptima π^* : mínimo coste esperado
 - ▶ **Acciones deterministas**: si la acción a lleva al estado s' , el **coste** es:

$$c(a) + \text{costeDesde}(s')$$

Para el caso de minimizar el coste

- ▶ Política óptima π^* : mínimo coste esperado
 - ▶ **Acciones deterministas**: si la acción a lleva al estado s' , el **coste** es:

$$c(a) + \text{costeDesde}(s')$$

- ▶ **Acciones no deterministas**: si la acción a tiene efectos probabílisticos, el **coste esperado** es:

$$c(a) + \sum_{s'} P(s'|s, a) \times \text{costeDesde}(s')$$

Para el caso de minimizar el coste

- ▶ Política óptima π^* : mínimo coste esperado
 - ▶ **Acciones deterministas**: si la acción a lleva al estado s' , el **coste** es:

$$c(a) + \text{costeDesde}(s')$$

- ▶ **Acciones no deterministas**: si la acción a tiene efectos probabílisticos, el **coste esperado** es:

$$c(a) + \sum_{s'} P(s'|s, a) \times \text{costeDesde}(s')$$

¿Cómo definimos una política óptima?

Función de valor: coste esperado de un estado

$V(s)$: coste esperado de alcanzar la meta desde s

Función de valor: coste esperado de un estado

$V(s)$: coste esperado de alcanzar la meta desde s

► Búsqueda:

- $V(s)$: coste del camino óptimo desde s
- Si conocemos $V(s)$, podemos utilizar $h(s) = V(s)$ con búsqueda en escalada
- $V(s)$ es la heurística perfecta $h^*(s)$

Función de valor: coste esperado de un estado

$V(s)$: coste esperado de alcanzar la meta desde s

► Búsqueda:

- $V(s)$: coste del camino óptimo desde s
- Si conocemos $V(s)$, podemos utilizar $h(s) = V(s)$ con búsqueda en escalada
- $V(s)$ es la heurística perfecta $h^*(s)$

► MDP

- $V(s)$: coste esperado de la estrategia óptima para alcanzar la meta desde s
- Si conocemos $V(s)$, podemos calcular una política óptima π^*

Función de valor: coste esperado de un estado

$V(s)$: coste esperado de alcanzar la meta desde s

► Búsqueda:

- $V(s)$: coste del camino óptimo desde s
- Si conocemos $V(s)$, podemos utilizar $h(s) = V(s)$ con búsqueda en escalada
- $V(s)$ es la heurística perfecta $h^*(s)$

► MDP

- $V(s)$: coste esperado de la estrategia óptima para alcanzar la meta desde s
- Si conocemos $V(s)$, podemos calcular una política óptima π^*

¿Cómo calculamos $V(s)$?

Calculando $V(S)$. Acciones deterministas

- Ecuaciones de Bellman

- Si s es un estado meta, $V(s) = 0$
 - En otro caso (s' es el estado que se genera aplicando a en s):

$$V(s) = \min_{a \in A(s)} [c(a) + V(s')]$$

- $A(s)$: acciones aplicables en s
 - $V(s)$ es una función heurística perfecta $h^*(s)$

Ecuaciones de Bellman para MDPs (acciones no deterministas)

- ▶ Dominios estocásticos:
 - ▶ El valor esperado a partir de la acción a :

$$c(a) + \sum_{s' \in S} P_a(s'|s)V(s')$$

Ecuaciones de Bellman para MDPs (acciones no deterministas)

- Dominios estocásticos:

- El valor esperado a partir de la acción a :

$$c(a) + \sum_{s' \in S} P_a(s'|s)V(s')$$

- Entonces,

- Si s es un estado meta, $V(s) = 0$
 - En otro caso

$$V(s) = \min_{a \in A(s)} [c(a) + \sum_{s' \in S} P_a(s'|s)V(s')]$$

Ecuaciones de Bellman para MDPs (acciones no deterministas)

- Dominios estocásticos:

- El valor esperado a partir de la acción a :

$$c(a) + \sum_{s' \in S} P_a(s'|s)V(s')$$

- Entonces,

- Si s es un estado meta, $V(s) = 0$
 - En otro caso

$$V(s) = \min_{a \in A(s)} [c(a) + \sum_{s' \in S} P_a(s'|s)V(s')]$$

- Política óptima

$$\pi^*(s) = \arg \min_a [c(a) + \sum_{s' \in S} P_a(s'|s)V^*(s')]$$

Resolviendo las ecuaciones de Bellman

Algoritmo Iteración de Valor (Value Iteration)

$V(s_g) = 0$ para todos los estados meta s_g y todas las iteraciones

Inicializar $V_0(s) = 0$ para el resto de estados /* iteración $i=0$ */

while not(Fin) **do**

for each estado $s \in S$

 /* iteración $i+1$ */

$V_{i+1}(s) := \min_{a \in A(s)} [c(a) + \sum_{s' \in S} P_a(s'|s) V_i(s')]$

 Política $\pi_{i+1} = \arg \min_{a \in A(s)} [c(a) + \sum_{s' \in S} P_a(s'|s) V_i(s')]$

return π_{last}

Cuando el algoritmo se estabiliza, $\pi^* = \pi_{last}$, es la política óptima

Terminación de Value Iteration

- ▶ *Value Iteration* termina cuando alcanza un *punto fijo*, es decir, cuando los valores no cambian en dos iteraciones sucesivas
- ▶ En la práctica termina cuando $\max_s |V_i(s) - V_{i+1}(s)| \leq \epsilon$

Para el caso de refuerzo

- ▶ Se introduce un **factor de descuento** $\gamma \in [0, 1]$

$$\max E \left[\sum_{t=0}^{\infty} \gamma^t R(s_t) \right]$$

- ▶ El algoritmo Iteración de Valor es similar, con los siguientes cambios:
 - ▶ $V(s_g) = R(s_g)$ para todos los estados meta s_g y todas las iteraciones
 - ▶ Maximizar: $V(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P_a(s'|s) V(s')]$
 - ▶ Política óptima

$$\pi^*(s) = \arg \max_a [\gamma \sum_{s' \in S} P_a(s'|s) V^*(s')]$$

Ejemplo *value iteration*: acciones deterministas

Para este ejemplo y los siguiente utilizaremos $\gamma = 1$

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} \left[\gamma \sum_{s' \in S} P(s'|s, a) V_i(s') \right]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (inicialización)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

Ejemplo *value iteration*: acciones deterministas

Para este ejemplo y los siguiente utilizaremos $\gamma = 1$

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (inicialización)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

Iteración $i=1$ (calcular $V_1(s)$ para todos los estados)

$$V_1(a3) = -3 + \max\{0, 0, 100, 0\} = 97$$

acciones en el máximo: NORTE, SUR, ESTE, OESTE
acción argmax: ESTE

Ejemplo *value iteration*: acciones deterministas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_1(s)$ para todos los estados (iteración 1)

	1	2	3	4
a	-3	-3	97	+100
b	-3		-3	-100
c	-3	-3	-3	-3

Iteración $i=2$ (calcular $V_2(s)$ para todos los estados)

$$V_2(b3) = -3 + \max\{97, -3, -100\} = 94$$

acciones en el máximo: NORTE, SUR, ESTE
OESTE no aplicable

acción argmax: NORTE


Ejemplo *value iteration*: acciones deterministas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_{last}(s)$ para todos los estados (iteración final) y la política óptima (derecha)

	1	2	3	4
a	91	94	97	+100
b	88		94	-100
c	85	88	91	88



Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (iteración 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (iteración 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$V_1(a3)?$

Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (iteración 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$V_1(a3)?$

► norte $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$

Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (iteración 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$V_1(a3)?$

- norte $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$
- sur $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$

Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (iteración 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$V_1(a3)?$

- norte $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$
- sur $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$
- este $\rightarrow 0.8 \times 100 + 0.1 \times 0 + 0.1 \times 0 = 80$

Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (iteración 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$V_1(a3)?$

- norte $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$
- sur $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$
- este $\rightarrow 0.8 \times 100 + 0.1 \times 0 + 0.1 \times 0 = 80$
- oeste $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 0 = 0$

Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_0(s)$ para todos los estados (iteración 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$V_1(a3)?$

- ▶ norte $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$
- ▶ sur $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 100 = 10$
- ▶ este $\rightarrow 0.8 \times 100 + 0.1 \times 0 + 0.1 \times 0 = 80$
- ▶ oeste $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times 0 = 0$

$V_1(a3) = -3 + \max\{10, 10, 80, 0\} = 77$
acción argmax: ESTE

Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_1(s)$ para todos los estados (iteración 1)

	1	2	3	4
a	-3	-3	77	+100
b	-3		-3	-100
c	-3	-3	-3	-3

Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

La imagen de abajo a la izquierda muestra $V_1(s)$ para todos los estados (iteración 1)

	1	2	3	4
a	-3	-3	77	+100
b	-3		-3	-100
c	-3	-3	-3	-3

$V_2(b3)?$

- norte $\rightarrow 0.8 \times 77 + 0.1 \times 0 + 0.1 \times -100 = 51.6$
- sur $\rightarrow 0.8 \times 0 + 0.1 \times 0 + 0.1 \times -100 = -10$
- este $\rightarrow 0.8 \times -100 + 0.1 \times 77 + 0.1 \times 0 = -72.3$
- oeste $\rightarrow 0.8 \times 0 + 0.1 \times 77 + 0.1 \times 0 = 7.7$

$V_2(b3) = -3 + \max\{51.6, -10, -72.3, 7.7\} = 48.6$
acción argmax: NORTE


Ejemplo *value iteration*: acciones estocásticas

	1	2	3	4
a	-3	-3	-3	+100
b	-3		-3	-100
c	-3 INICIO	-3	-3	-3

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

Resultado de la última iteración y política óptima

	1	2	3	4
a	85	89	93	+100
b	81		68	-100
c	77	73	70	47



Ejemplo *value iteration*: acciones estocásticas (Refuerzos 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

Resultado de la última iteración y política óptima

Ejemplo *value iteration*: acciones estocásticas (Refuerzos 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

Resultado de la última iteración y política óptima

	1	2	3	4
a	100	100	100	+100
b	100		100	-100
c	100	100	100	100


Ejemplo *value iteration*: acciones estocásticas (Refuerzos 0)

	1	2	3	4
a	0	0	0	+100
b	0		0	-100
c	0	0	0	0

$$V_{i+1}(s) := R(s) + \max_{a \in A(s)} [\gamma \sum_{s' \in S} P(s'|s, a) V_i(s')]$$

Resultado de la última iteración y política óptima

	1	2	3	4
a	100	100	100	+100
b	100		100	-100
c	100	100	100	100



Ejemplo de Value Iteration

- ▶ Estados: s_1, s_2, s_3
- ▶ Meta: s_3
- ▶ Acciones
 - ▶ Acción **Derecha**
 - ▶ s_i pasa a s_{i+1} con probabilidad 0.8
 - ▶ con probabilidad 0.2, permanece en s_i
 - ▶ coste: 1
 - ▶ Acción **Izquierda**
 - ▶ s_i pasa a s_{i-1} con probabilidad 0.8
 - ▶ con probabilidad 0.2, permanece en s_i
 - ▶ coste: 1
- ▶ Inicialmente: $V(s_1) = V(s_2) = 0$
- ▶ $V(s_3) = 0$ siempre porque es la meta

Ejemplo de Value Iteration

Iteración 1: $V(s_1) = c(\text{Derecha}) + (0.8V(s_2) + 0.2V(s_1)) = 1$

$$V(s_2) = \min\{c(\text{Derecha}) + (0.8V(s_3) + 0.2V(s_2)), c(\text{Izquierda}) + (0.8V(s_1) + 0.2V(s_2))\} = \min\{1, 1\} = 1$$

Ejemplo de Value Iteration

Iteración 1: $V(s_1) = c(\text{Derecha}) + (0.8V(s_2) + 0.2V(s_1)) = 1$

$$V(s_2) = \min\{c(\text{Derecha}) + (0.8V(s_3) + 0.2V(s_2)), c(\text{Izquierda}) + (0.8V(s_1) + 0.2V(s_2))\} = \min\{1, 1\} = 1$$

Iteración 2: $V(s_1) = 1 + (0.8 \times 1 + 0.2 \times 1) = 2$

$$V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1), 1 + (0.8 \times 1 + 0.2 \times 1)\} = \min\{1.2, 2\} = 1.2$$

Ejemplo de Value Iteration

Iteración 1: $V(s_1) = c(\text{Derecha}) + (0.8V(s_2) + 0.2V(s_1)) = 1$
 $V(s_2) = \min\{c(\text{Derecha}) + (0.8V(s_3) + 0.2V(s_2)), c(\text{Izquierda}) + (0.8V(s_1) + 0.2V(s_2))\} = \min\{1, 1\} = 1$

Iteración 2: $V(s_1) = 1 + (0.8 \times 1 + 0.2 \times 1) = 2$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1), 1 + (0.8 \times 1 + 0.2 \times 1)\} = \min\{1.2, 2\} = 1.2$

Iteración 3: $V(s_1) = 1 + (0.8 \times 1.2 + 0.2 \times 2) = 2.36$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.2), 1 + (0.8 \times 2 + 0.2 \times 1.2)\} = \min\{1.24, 2.84\}$

Ejemplo de Value Iteration

Iteración 1: $V(s_1) = c(\text{Derecha}) + (0.8V(s_2) + 0.2V(s_1)) = 1$
 $V(s_2) = \min\{c(\text{Derecha}) + (0.8V(s_3) + 0.2V(s_2)), c(\text{Izquierda}) + (0.8V(s_1) + 0.2V(s_2))\} = \min\{1, 1\} = 1$

Iteración 2: $V(s_1) = 1 + (0.8 \times 1 + 0.2 \times 1) = 2$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1), 1 + (0.8 \times 1 + 0.2 \times 1)\} = \min\{1.2, 2\} = 1.2$

Iteración 3: $V(s_1) = 1 + (0.8 \times 1.2 + 0.2 \times 2) = 2.36$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.2), 1 + (0.8 \times 2 + 0.2 \times 1.2)\} = \min\{1.24, 2.84\}$

Iteración 4: $V(s_1) = 1 + (0.8 \times 1.24 + 0.2 \times 2.36) = 2.464$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.24), 1 + (0.8 \times 2.36 + 0.2 \times 1.24)\} = 1.248$

Ejemplo de Value Iteration

Iteración 1: $V(s_1) = c(\text{Derecha}) + (0.8V(s_2) + 0.2V(s_1)) = 1$
 $V(s_2) = \min\{c(\text{Derecha}) + (0.8V(s_3) + 0.2V(s_2)), c(\text{Izquierda}) + (0.8V(s_1) + 0.2V(s_2))\} = \min\{1, 1\} = 1$

Iteración 2: $V(s_1) = 1 + (0.8 \times 1 + 0.2 \times 1) = 2$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1), 1 + (0.8 \times 1 + 0.2 \times 1)\} = \min\{1.2, 2\} = 1.2$

Iteración 3: $V(s_1) = 1 + (0.8 \times 1.2 + 0.2 \times 2) = 2.36$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.2), 1 + (0.8 \times 2 + 0.2 \times 1.2)\} = \min\{1.24, 2.84\}$

Iteración 4: $V(s_1) = 1 + (0.8 \times 1.24 + 0.2 \times 2.36) = 2.464$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.24), 1 + (0.8 \times 2.36 + 0.2 \times 1.24)\} = 1.248$

Iteración 5: $V(s_1) = 1 + (0.8 \times 1.248 + 0.2 \times 2.464) = 2.4912$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.248), 1 + (0.8 \times 2.464 + 0.2 \times 1.248)\} = 1.2496$

Ejemplo de Value Iteration

Iteración 1: $V(s_1) = c(\text{Derecha}) + (0.8V(s_2) + 0.2V(s_1)) = 1$
 $V(s_2) = \min\{c(\text{Derecha}) + (0.8V(s_3) + 0.2V(s_2)), c(\text{Izquierda}) + (0.8V(s_1) + 0.2V(s_2))\} = \min\{1, 1\} = 1$

Iteración 2: $V(s_1) = 1 + (0.8 \times 1 + 0.2 \times 1) = 2$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1), 1 + (0.8 \times 1 + 0.2 \times 1)\} = \min\{1.2, 2\} = 1.2$

Iteración 3: $V(s_1) = 1 + (0.8 \times 1.2 + 0.2 \times 2) = 2.36$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.2), 1 + (0.8 \times 2 + 0.2 \times 1.2)\} = \min\{1.24, 2.84\}$

Iteración 4: $V(s_1) = 1 + (0.8 \times 1.24 + 0.2 \times 2.36) = 2.464$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.24), 1 + (0.8 \times 2.36 + 0.2 \times 1.24)\} = 1.248$

Iteración 5: $V(s_1) = 1 + (0.8 \times 1.248 + 0.2 \times 2.464) = 2.4912$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.248), 1 + (0.8 \times 2.464 + 0.2 \times 1.248)\} = 1.2496$

Iteración 6: $V(s_1) = 1 + (0.8 \times 1.2496 + 0.2 \times 2.4912) = 2.49792$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.2496), 1 + (0.8 \times 2.4912 + 0.2 \times 1.2496)\} = 1.24992$

Ejemplo de Value Iteration

Iteración 1: $V(s_1) = c(\text{Derecha}) + (0.8V(s_2) + 0.2V(s_1)) = 1$
 $V(s_2) = \min\{c(\text{Derecha}) + (0.8V(s_3) + 0.2V(s_2)), c(\text{Izquierda}) + (0.8V(s_1) + 0.2V(s_2))\} = \min\{1, 1\} = 1$

Iteración 2: $V(s_1) = 1 + (0.8 \times 1 + 0.2 \times 1) = 2$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1), 1 + (0.8 \times 1 + 0.2 \times 1)\} = \min\{1.2, 2\} = 1.2$

Iteración 3: $V(s_1) = 1 + (0.8 \times 1.2 + 0.2 \times 2) = 2.36$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.2), 1 + (0.8 \times 2 + 0.2 \times 1.2)\} = \min\{1.24, 2.84\}$

Iteración 4: $V(s_1) = 1 + (0.8 \times 1.24 + 0.2 \times 2.36) = 2.464$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.24), 1 + (0.8 \times 2.36 + 0.2 \times 1.24)\} = 1.248$

Iteración 5: $V(s_1) = 1 + (0.8 \times 1.248 + 0.2 \times 2.464) = 2.4912$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.248), 1 + (0.8 \times 2.464 + 0.2 \times 1.248)\} = 1.2496$

Iteración 6: $V(s_1) = 1 + (0.8 \times 1.2496 + 0.2 \times 2.4912) = 2.49792$
 $V(s_2) = \min\{1 + (0.8 \times 0 + 0.2 \times 1.2496), 1 + (0.8 \times 2.4912 + 0.2 \times 1.2496)\} = 1.24992$

Política óptima π^* : $\pi^*(s_1) = \text{derecha}$, $\pi^*(s_2) = \text{derecha}$

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

Introducción

Modelos de Markov

Modelos de Markov Ocultos (HMMs)

Procesos de Decisión de Markov (MDPs)

Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa

Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

- ▶ Proceso de Markov + observabilidad parcial = HMM
- ▶ Proceso de Markov + acciones = MDP
- ▶ Proceso de Markov + observabilidad parcial + acciones = HMM + acciones = MDP + observabilidad parcial = POMDP

acciones	observabilidad total	observabilidad parcial
no	Proceso de Markov	HMM
si	MDP	POMDP

Créditos

- ▶ Material UC3M de cursos anteriores
- ▶ Libro *Artificial Intelligence: a modern approach*. Russell and Norving. Prentice Hall. 2003
- ▶ Material docente de Andrew M. Moore. Carnegie Mellon University.
<http://www.cs.cmu.edu/~awm/tutorials>
- ▶ Video de Sebastian Thrun. Stanford University.
https://www.youtube.com/watch?v=DgH6NaJHfVQ&list=PLTnAYbE3sS--_h8N7dTp9vm8MRT2m1IOD

En este tema

Incertidumbre

Razonamiento Probabilístico

Redes Bayesianas

Razonamiento Probabilístico en el tiempo

- Introducción

- Modelos de Markov

- Modelos de Markov Ocultos (HMMs)

- Procesos de Decisión de Markov (MDPs)

- Procesos de Decisión de Markov Parcialmente Observables (POMDPs)

Lógica Borrosa